

Аналитический отчет по задаче прогнозирования эффективности химических соединений

1. Введение

Цель работы - построить и сравнить модели машинного обучения для анализа химических соединений и прогнозирования показателей, связанных с их эффективностью против вируса гриппа.

В распоряжении имеются данные о химических соединениях. Для каждого соединения представлены числовые химические дескрипторы, а также целевые показатели:

IC50, mM	Показатель связан с противовирусной активностью соединения. Чем ниже значение IC50, тем меньшая концентрация соединения требуется для достижения эффекта.
CC50, mM	Показатель связан с цитотоксичностью. Чем выше значение CC50, тем большая концентрация требуется для проявления токсического эффекта.
SI	Показатель является расчетной величиной и определяется через отношение $CC50 / IC50$. Чем выше SI, тем более перспективным может быть соединение с точки зрения баланса эффективности и безопасности.

В рамках работы решались следующие задачи:

- регрессия для IC50;
- регрессия для CC50;
- регрессия для SI;
- классификация $IC50 > median$;
- классификация $CC50 > median$;
- классификация $SI > median$;
- классификация $SI > 8$.

Для каждой задачи были проверены разные модели, выполнено сравнение качества, проведен подбор гиперпараметров и сделаны выводы о применимости подходов.

2. Описание данных

Датасет содержит информацию о 1001 химических соединений. Большая часть признаков является числовыми химическими дескрипторами.

3. Разведочный анализ данных


На этапе EDA были выполнены следующие шаги:

- проверка структуры данных;
- анализ пропущенных значений;
- анализ распределений целевых переменных;
- проверка связи между IC50, CC50 и SI;
- анализ корреляций;
- анализ возможности применения логарифмического преобразования

3.1. Распределение целевых переменных

Анализ распределения целевых признаков:

- распределения значений IC50, CC50 и SI имеют правостороннюю асимметрию
- большинство значений сосредоточено в области низких значений
- боксплоты показывают выбросы и аномалии.



Из-за такой структуры данных рационально применить логарифмическое преобразование целевых переменных, что позволяет уменьшить влияние экстремальных значений и сделать распределения близко к нормальному.

3.2. Корреляционный анализ

Был проведен корреляционный анализ при помощи Phi_k корреляции. Главное преимущество Phi-K заключается в универсальности и способности улавливать нелинейные зависимости.

При пороге корреляции 0,8 было обнаружено 135 созависимых параметров. В результате корреляционного анализа мы избавились от мультиколлинеарности.

3.3. Анализ пропущенных значений

В результате были обнаружены пропуски в данных в количестве 36 штук, что является незначительным количеством. Часть параметров с пропусками была удалена в результате универсального корреляционного анализа, а оставшаяся часть была заменена на медианные значения, для минимизации влияния выбросов и аномалий.

3.4. Расчетная природа SI

Параметр SI рассчитывается на основе IC50 и CC50. В данных этот параметр был без пропусков, поэтому мы не применяли дополнительных вычислений

Так как SI зависит от IC50 и CC5, то во избежание утечек эти признаки при прогнозировании SI использовать нельзя - это приведет к утечке данных.

4. Подготовка данных

Для всех задач были проделаны следующие операции:

- удаление технических столбцов;
- исключение целевых переменных из признаков;
- заполнение пропущенных значений медианой;
- логарифмирование целевых признаков
- приведение признаков к единому масштабу - стандартизация признаков.

Для оценки моделей использовались следующие метрики:

- Для регрессии: MAE, RMSE, R2
- Для классификации: accuracy, precision, recall, F1, ROC-AUC


5. Регрессионные задачи

5.1. Регрессия IC50

Для прогнозирования IC50 были проверены несколько моделей:

Model	RMSE_log	R^2_log
RandomForest	0.720225	0.479328
LightGBM	0.748016	0.438370
KNN	0.754449	0.428668
XGBoost	0.772379	0.401189
Ridge	0.860283	0.257134
LinearRegression	0.860690	0.256431
Lasso	1.001649	-0.007068

По результатам сравнения видно, что наилучшее качество показывает RandomForest. Линейные модели работают заметно хуже, делаем выводы об отсутствии выраженной линейной зависимости в данных.




Высокий RMSE и низкий R² говорят о том, что модель плохо улавливает зависимость и дает значительные ошибки в предсказании IC50.

5.2. Регрессия CC50

Для прогнозирования CC50 были использованы те же группы моделей.

Model	RMSE_log	R^2_log
RandomForest	0.502286	0.436108
LightGBM	0.522607	0.389559
XGBoost	0.541004	0.345823
KNN	0.541081	0.345638
Ridge	0.578881	0.251015
LinearRegression	0.579289	0.249961
Lasso	0.672180	-0.009870

По результатам сравнения видно, что наилучшее качество показывает RandomForest




Качество модели умеренное. Метрики: RMSE составляет 516.55 mM, а коэффициент детерминации $R^2 = 0.485$. Значение коэффициента детерминации говорит о том, что модель объясняет чуть менее половины дисперсии данных (48.5%). Также модель может занижать предсказания для самых высоких значений. Точки ниже идеального предсказания.

5.3. Регрессия SI

Для прогнозирования SI были использованы те же группы моделей.

Model	RMSE_log	R^2_log
RandomForest	0.669902	0.264435
LightGBM	0.671933	0.259969
KNN	0.689803	0.220082
XGBoost	0.707648	0.179207
Ridge	0.731196	0.123673
LinearRegression	0.731398	0.123189
Lasso	0.781284	-0.000500

По результатам сравнения видно, что наилучшее качество показывает снова RandomForest



Качество модели крайне низкое. $R^2 = 0.001$: модель объясняет менее 0.1% дисперсии данных. Это практически случайный прогноз.

Задача прогнозирования SI оказалась наиболее сложной среди регрессионных задач. SI является производной величиной от IC50 и CC50. Поскольку эти параметры были исключены из признаков для предотвращения утечки данных, задача предсказания SI становится более сложной.

Итог:

1. По качеству задача CC50 оказалась немного стабильнее, чем задача IC50. Модели лучше улавливают закономерности, связанные с цитотоксичностью, чем закономерности, связанные с противовирусной активностью.
2. Модель SI не пригодна для практического использования в текущем виде — она не улавливает зависимость между признаками и целевой переменной.

6. Классификационные задачи

В задачах данного типа требовалось предсказать, превышает ли значение IC50, CC50 и SI медианное значение выборки.

6.1. Классификация IC50 выше медианы

Так как порогом была медиана, классы получились примерно сбалансированными.

Пропорция распределения:

proportion	
IC50, mM	
0	0.5005
1	0.4995

Наилучший результат по F1 показали GradientBoostingClassifier и RandomForestClassifier.

Сравнение моделей без настройки:

	Модель	Accuracy	F1	ROC-AUC
5	GradientBoosting	0.691542	0.720721	0.758267
3	RandomForest	0.686567	0.712329	0.754851
0	KNN	0.701493	0.711538	0.768713
6	LightGBM	0.676617	0.697674	0.741337
2	LogisticRegression	0.666667	0.682464	0.718960
4	ExtraTrees	0.656716	0.672986	0.719802
1	DecisionTree	0.597015	0.604878	0.610792

После подбора гиперпараметров лучшей моделью стала RandomForestClassifier.

Результаты финальной модели:


Результаты RandomForest на тесте:
Accuracy: 0.7114
F1-score: 0.7339
ROC-AUC: 0.7743

Classification Report:				
	precision	recall	f1-score	support
0	0.76	0.62	0.68	101
1	0.68	0.80	0.73	100
accuracy			0.71	201
macro avg	0.72	0.71	0.71	201
weighted avg	0.72	0.71	0.71	201


Модель демонстрирует хорошее качество ($F1 = 0.73$), высокий ROC-AUC (0.7743) - модель хорошо ранжирует объекты.

Хорошая полнота (Recall) для класса 1 (0.80) - модель редко пропускает объекты с высоким IC50. Низкая полнота (Recall) для класса 0 (0.62) - модель пропускает почти 38% объектов этого класса.

Матрица ошибок



Матрица ошибок показывает, что модель достаточно хорошо разделяет соединения по значению IC50 относительно медианы. Модель правильно классифицировала 63 объекта класса **IC50 <= median** и 80 объектов класса **IC50 > median**.



ROC-кривая показывает, что модель хорошо отделяет соединения с IC50 выше медианы от остальных. Значение AUC составляет около 0.77, что заметно выше случайного угадывания 0.5.

6.2. Классификация CC50 выше медианы

Бинарная классификация позволяет разделить соединения на группы с более низким и более высоким уровнем токсичности.

Так как порогом была медиана, классы получились примерно сбалансированными.

Пропорция распределения:

proportion	
CC50, mM	
0	0.501499
1	0.498501

Наилучший результат по F1 показали GradientBoostingClassifier и LightGBM.

Сравнение моделей без настройки:

	Модель	Accuracy	F1	ROC-AUC
6	LightGBM	0.746269	0.762791	0.850495
5	GradientBoosting	0.736318	0.757991	0.834604
3	RandomForest	0.731343	0.750000	0.840446
4	ExtraTrees	0.726368	0.739336	0.838465
0	KNN	0.721393	0.735849	0.773416
1	DecisionTree	0.701493	0.719626	0.727574
2	LogisticRegression	0.696517	0.710900	0.777822

После подбора гиперпараметров лучшей моделью стала LightGBM.
Результаты финальной модели:

Результаты LightGBM на тесте:

Accuracy: 0.7363

F1-score: 0.7580

ROC-AUC: 0.8484


Classification Report:

	precision	recall	f1-score	support
0	0.79	0.64	0.71	101
1	0.70	0.83	0.76	100
accuracy			0.74	201
macro avg	0.75	0.74	0.73	201
weighted avg	0.75	0.74	0.73	201

Модель демонстрирует хорошее качество ($F1 = 0.76$), высокий ROC-AUC (0.848) - модель хорошо ранжирует объекты.


Хорошая полнота (Recall) для класса 1 (0.83) — модель редко пропускает объекты с высоким CC50. Низкая полнота (Recall) для класса 0 (0.64) — модель пропускает почти 38% объектов этого класса.

Матрица ошибок



Матрица ошибок показывает, что модель достаточно хорошо разделяет соединения по значению CC50 относительно медианы. Модель правильно классифицировала 65 объекта класса CC50 <= median и 83 объектов класса CC50 > median.

Модель допустила 36 ложноположительных ошибок и 17 ложноотрицательных ошибок.



ROC-кривая показывает, что модель хорошо отделяет соединения с CC50 выше медианы от остальных. Значение AUC составляет около 0.85, что заметно выше случайного угадывания 0.5.

Задача **CC50 > median** оказалась наиболее качественно решаемой среди классификационных задач.

6.3. Классификация SI выше медианы

Параметр SI является расчетным показателем и связан с соотношением CC50 и IC50. Более высокий SI означает более выгодное сочетание эффективности и токсичности соединения.

Так как SI рассчитывается на основе IC50 и CC50, эти параметры не используются в качестве признаков при обучении модели, чтобы избежать утечки данных

Так как порогом была медиана, классы получились примерно сбалансированными.

Пропорция распределения:

proportion

SI

0	0.5005
1	0.4995

Наилучший результат по F1 показали GradientBoostingClassifier и KNeighborsClassifier

Сравнение моделей без настройки:

	Model	Accuracy	F1	ROC-AUC
0	KNN	0.671642	0.682692	0.733861
6	GradientBoosting	0.636816	0.621762	0.682327
3	RandomForest	0.636816	0.617801	0.666535
2	LogisticRegression	0.646766	0.616216	0.649257
4	ExtraTrees	0.621891	0.616162	0.655446
7	LightGBM	0.621891	0.612245	0.646782
5	XGBoost	0.606965	0.594872	0.650743
1	DecisionTree	0.562189	0.568627	0.552079

После подбора гиперпараметров лучшей моделью стала KNeighborsClassifier.

Результаты финальной модели:

Результаты KNN на тесте:
Accuracy: 0.6965
F1-score: 0.6904
ROC-AUC: 0.7604


Classification Report:

	precision	recall	f1-score	support
0	0.69	0.71	0.70	101
1	0.70	0.68	0.69	100
accuracy			0.70	201
macro avg	0.70	0.70	0.70	201
weighted avg	0.70	0.70	0.70	201

Модель демонстрирует хорошее качество ($F1 = 0.70$), хороший ROC-AUC (0.76) — модель хорошо ранжирует объекты.

Сравнивая полнота (Recall) для класса 0 и 1 (около 0,7)


Матрица ошибок



Матрица ошибок показывает, что модель достаточно хорошо разделяет соединения по значению SI относительно медианы. Модель правильно классифицировала 72 объекта класса SI <= median и 68 объектов класса SI > median.

Модель допустила 29 ложноположительных ошибок и 32 ложноотрицательных ошибок.

В целом модель сбалансирована. Она одинаково находит классы 1 и 0. Но также одинаково допускает ошибки - модель делает ошибки в обе стороны



ROC-кривая показывает, что модель хорошо отделяет соединения с SI выше медианы от остальных. Значение AUC составляет около 0.76, что заметно выше случайного угадывания 0.5.

ИТОГ

- Задача **CC50 > median** оказалась наиболее качественно решаемой среди классификационных задач.

6.4. Классификация SI больше 8

В данном ноутбуке решается задача бинарной классификации со строго заданным порогом: прогнозируется, является ли значение индекса селективности (SI) больше 8.

В отличие от задач классификации относительно медианы, здесь классы оказались умеренно несбалансированными:

Пропорция распределения:

```
proportion
SI
0    0.643357
1    0.356643
```

Наилучший результат по F1 показали RandomForestClassifier и KNeighborsClassifier.

Сравнение моделей без настройки:

	Model	Precision	Recall	F1	ROC-AUC
0	KNN	0.594203	0.569444	0.581560	0.701281
3	RandomForest	0.622951	0.527778	0.571429	0.727444
2	LogisticRegression	0.582090	0.541667	0.561151	0.683947
7	LightGBM	0.593750	0.527778	0.558824	0.723353
4	ExtraTrees	0.587302	0.513889	0.548148	0.711779
5	XGBoost	0.567164	0.527778	0.546763	0.718508
6	GradientBoosting	0.580645	0.500000	0.537313	0.716731
1	DecisionTree	0.486486	0.500000	0.493151	0.602606

В целом качество моделей можно считать умеренным. Это связано с тем, что задача $SI > 8$ сложнее классификации относительно медианы: положительный класс встречается реже.

После подбора гиперпараметров лучшей моделью стала KNeighborsClassifier.


Результаты KNN на тесте:
F1-score: 0.5931
ROC-AUC: 0.6946

Classification Report:				
	precision	recall	f1-score	support
0	0.77	0.77	0.77	129
1	0.59	0.60	0.59	72
accuracy			0.71	201
macro avg	0.68	0.68	0.68	201
weighted avg	0.71	0.71	0.71	201


Модель стабильна: оценка на тесте (0.5931). Проблема дисбаланса: класс 1 предсказывается хуже (Recall = 0.60), что типично для меньших классов.

Общая оценка: результат посредственный. KNN с такими гиперпараметрами не является сильным классификатором для этой задачи.

Матрица ошибок



Матрица ошибок показывает, что финальная модель лучше распознает класс SI <= 8, чем класс SI > 8. Модель правильно классифицировала 99 объектов класса 0 (SI <= 8) и 43 объекта класса 1 (SI > 8). Для положительного класса SI > 8 модель нашла 43 из 72, то есть recall составляет около 60%.



ROC-кривая показывает, что финальная модель KNN разделяет классы лучше случайного классификатора ($0,69 > 0,5$). При этом качество разделения нельзя назвать высоким. Модель показывает умеренный результат: она способна находить часть соединений с $SI > 8$, но допускает заметное количество ошибок.

7. Общие выводы

- В рамках исследования были разработаны модели для решения задач как регрессии, так и классификации.
- Предварительный анализ данных (EDA) выявил следующие особенности: целевые переменные отличались сильной асимметрией распределения и наличием выбросов.
- При сравнении сложности задач выяснилось, что регрессионные модели строились труднее, чем классификационные. Алгоритмы хорошо справлялись с аппроксимацией основной массы данных, однако их предсказательная способность заметно снижалась при работе с экстремальными значениями. Наибольшие трудности вызвала регрессия по показателю **SI**.
- Результаты классификации относительно медианы оказались более стабильными. Лучшим результатом среди них стала задача **CC50 > median**.
- Задачи с метрикой **SI** оказались наиболее трудоёмкими. Это объясняется тем, что **SI** характеризует не изолированную характеристику (активность или токсичность), а их соотношение. При этом в модели не использовались исходные показатели **IC50** и **CC50** в качестве признаков.
- Для задачи **SI > 8** алгоритм KNN продемонстрировал результат выше случайного угадывания, однако итоговое качество модели осталось на умеренном уровне. Это позволяет использовать её лишь в качестве предварительного фильтра для первичного отбора кандидатов, но не как самодостаточный инструмент для принятия финальных решений.

Итог

В ходе работы построены и валидированы модели для всех целевых задач.

Ключевые результаты:

- **Лучшие показатели** достигнуты в задачах классификации $IC50 > median$ и особенно $CC50 > median$.
- **Задачи с метрикой SI** оказались более сложными, но модели стабильно превосходили случайный прогноз (baseline).
- **Наиболее устойчивые архитектуры** — ансамблевые модели деревьев решений и KNN

Главный вывод:

Химические дескрипторы содержат значимую информацию для предварительной оценки эффективности и безопасности соединений. Однако для практического внедрения требуется **дальнейшая доработка** (увеличение объема данных, улучшение качества моделей) и **совместная интерпретация** результатов специалистами обеих областей — химиками и data scientists.